O que faz um vinho ser excelente?

Como dados de laboratório podem antecipar a qualidade de vinhos tintos



Tech Challenge · Fase 2 · PósTech Data Analytics — FIAP

A qualidade só é conhecida no fim — e depende de quem prova



Subjetiva

A nota vem de provas sensoriais e depende da experiência de cada especialista.



Tardia

A avaliação acontece quando o vinho já está pronto — tarde para corrigir o lote.



Os dados já existem

A vinícola já mede acidez, álcool, sulfatos e outras 8 características na produção.

A pergunta deste trabalho

Com as medições de laboratório, conseguimos antecipar quais lotes serão de alta qualidade — e saber o que ajustar no processo?

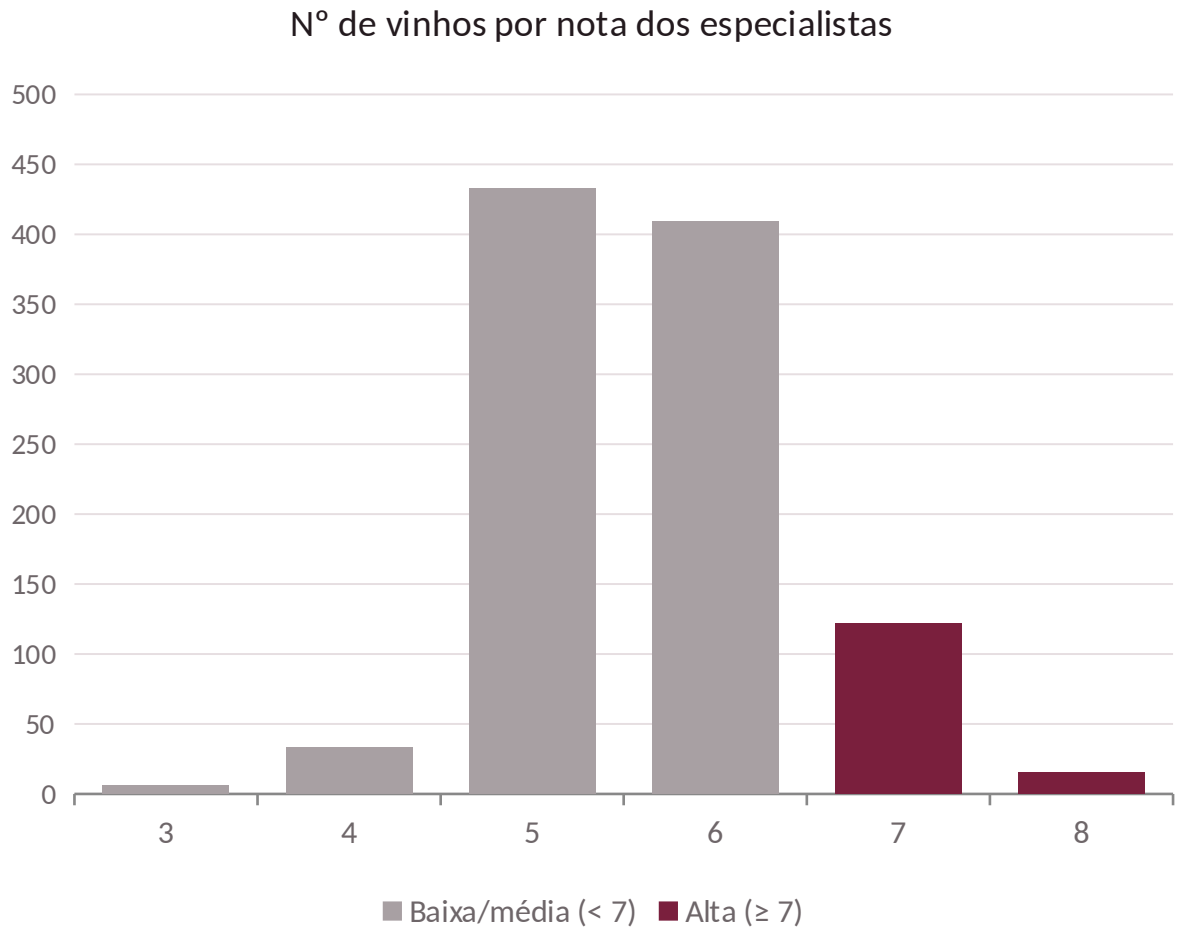
Analisamos 1.018 vinhos tintos e 11 medições de laboratório

1.143 amostras recebidas (base pública Wine Quality, Kaggle)

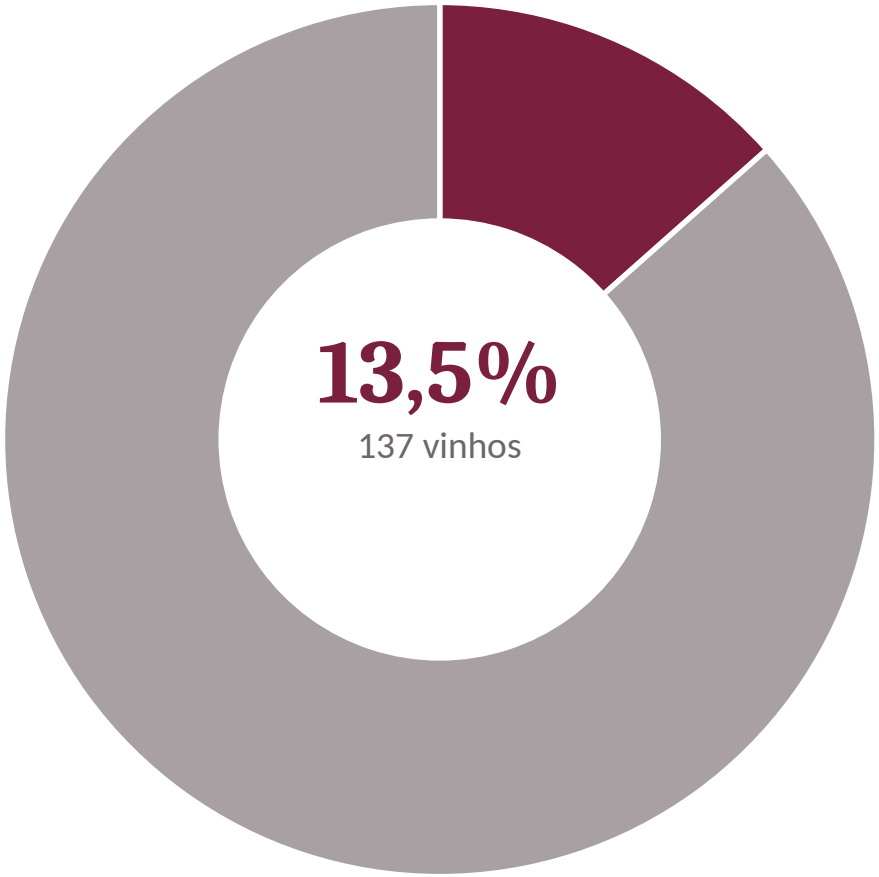
125 repetições removidas (10,9%) para não contar o mesmo vinho duas vezes

1.018 vinhos únicos analisados

0 dados faltantes



Só 1 em cada 7 vinhos é de alta qualidade



A armadilha da "taxa de acerto"

Quem dissesse "comum" para todos os vinhos acertaria 86,5% das vezes — e não encontraria nenhum vinho excelente.

Como medimos o sucesso

Pela capacidade de encontrar os vinhos excelentes sem disparar alarmes falsos demais (F1, que equilibra os dois erros).

Três características separam os vinhos excelentes dos comuns

Teor alcoólico

11,7%

nos vinhos excelentes

10,0% nos comuns · **+17%**

Uvas mais maduras e fermentação completa

Acidez volátil

0,36

nos vinhos excelentes

0,55 nos comuns · **−35%**

É o ácido acético: em excesso, cheiro de vinagre

Sulfatos

0,74

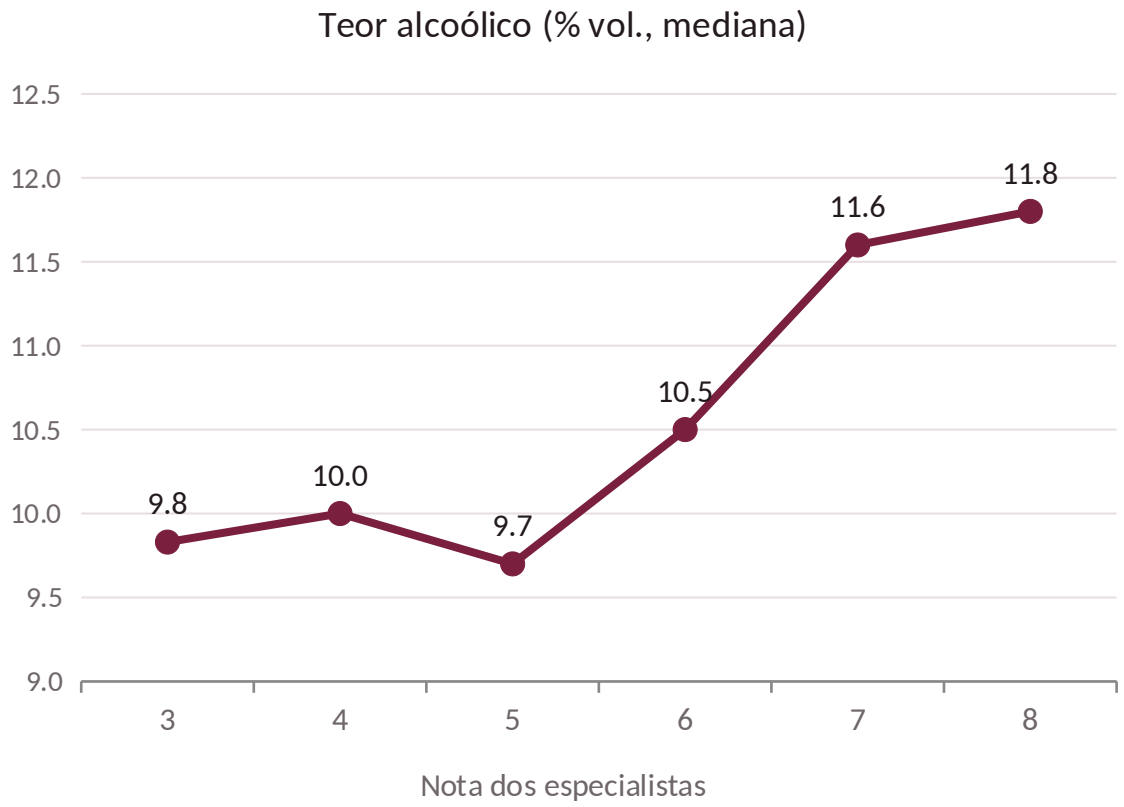
nos vinhos excelentes

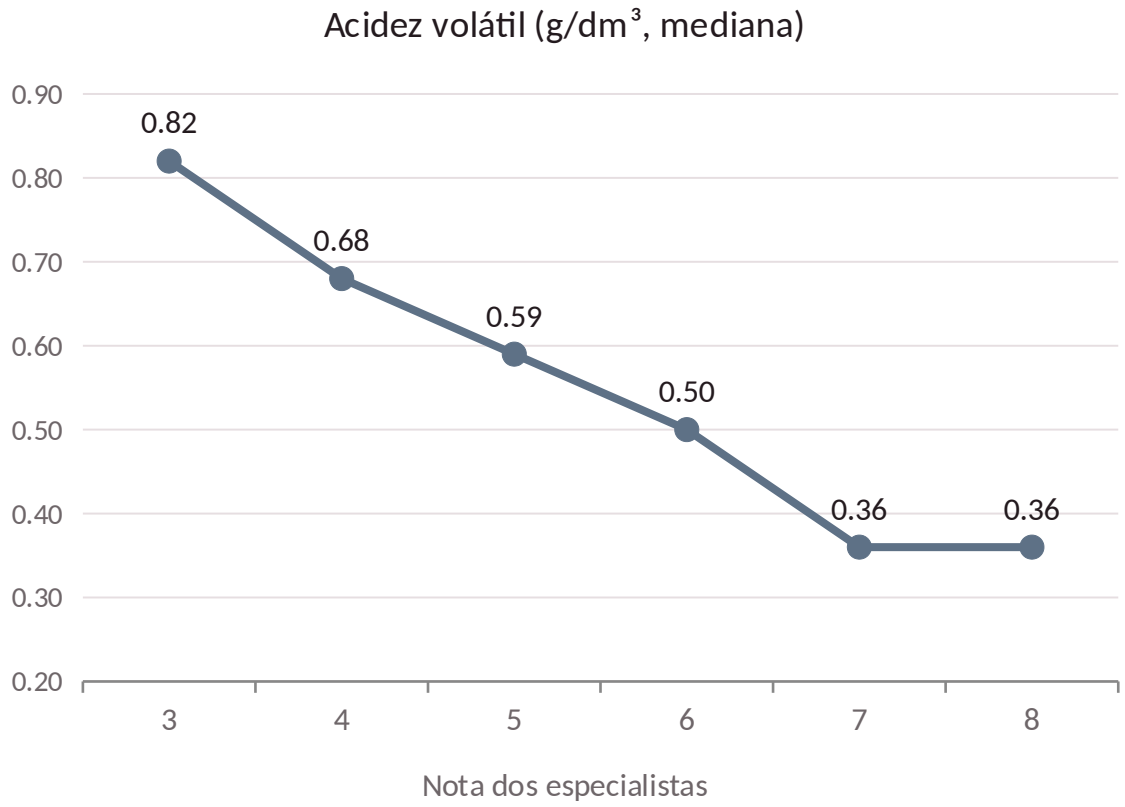
0,60 nos comuns · **+23%**

Protegem o vinho contra oxidação e micróbios

Medianas de cada grupo; acidez volátil e sulfatos em g/dm³. Diferenças confirmadas pelo teste de Mann-Whitney ($p < 0,001$); efeito grande para álcool e acidez volátil, no limite de grande para sulfatos.

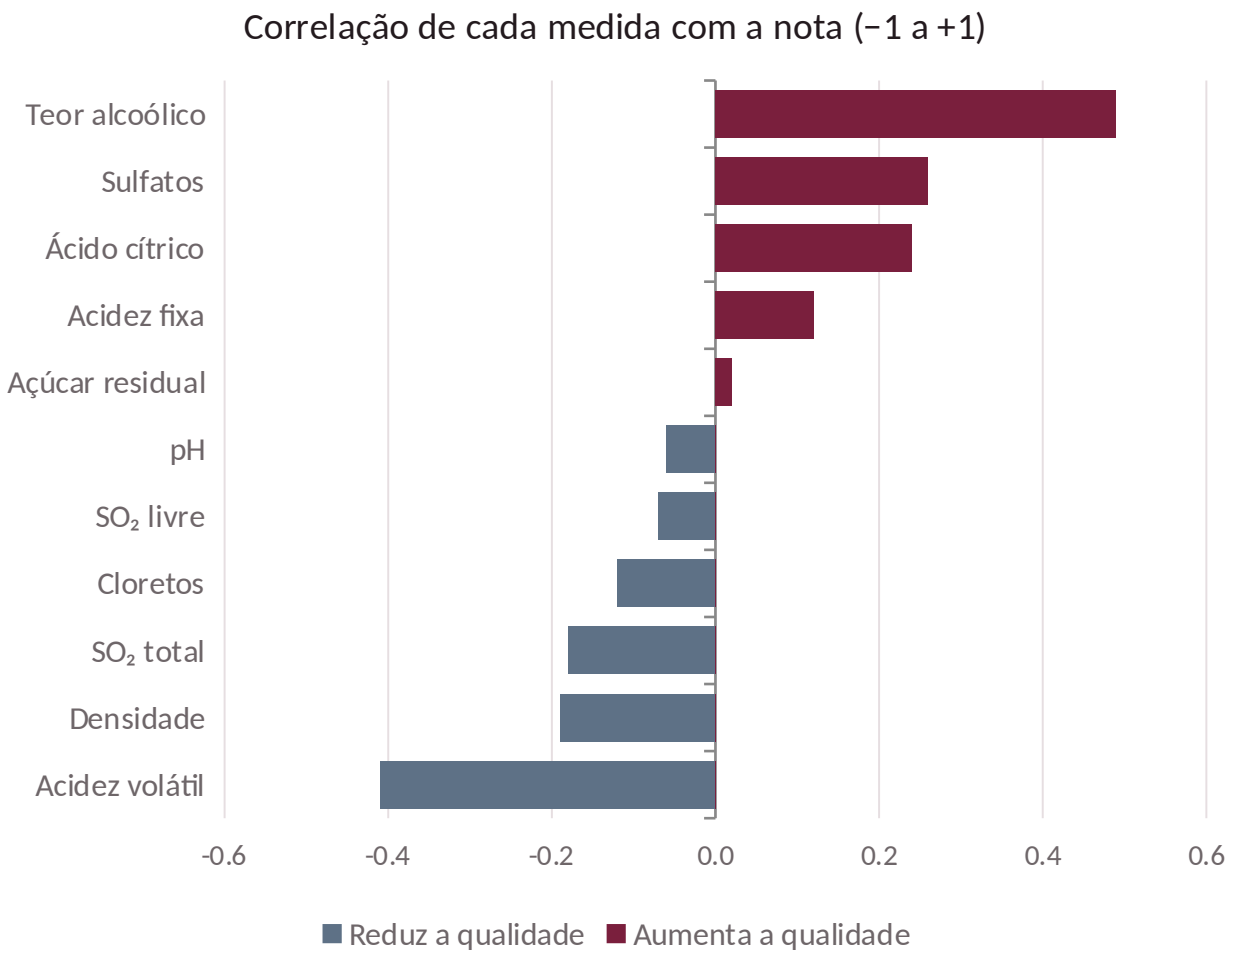
Quanto maior a nota, mais álcool e menos acidez volátil





O padrão não depende do corte em 7: da nota 5 à nota 8, o álcool sobe de 9,7% para 11,8% e a acidez volátil cai de 0,59 para 0,36 g/dm³.

Nenhuma medida decide sozinha: vale a combinação



Teor alcoólico (+0,49)
maior relação; reflete maturação e fermentação completa

Acidez volátil (−0,41)
defeito clássico (vinagre), penalizado na prova

Sulfatos e ácido cítrico (+0,26 / +0,24)
conservação e frescor

Densidade (−0,19)
efeito indireto: cai quando o álcool sobe

Açúcar, pH e SO_2 livre (≈ 0)
variam pouco em tintos secos; não diferenciam

Quatro cuidados com os dados antes de construir o modelo

Repetições removidas

10,9% das linhas eram cópias exatas. Mantê-las faria o modelo ser testado em vinhos que já tinha visto.

Valores extremos mantidos

Sal e conservante muito altos são reais e informativos: nesses vinhos, só 6% são excelentes (contra 13,5% no geral).

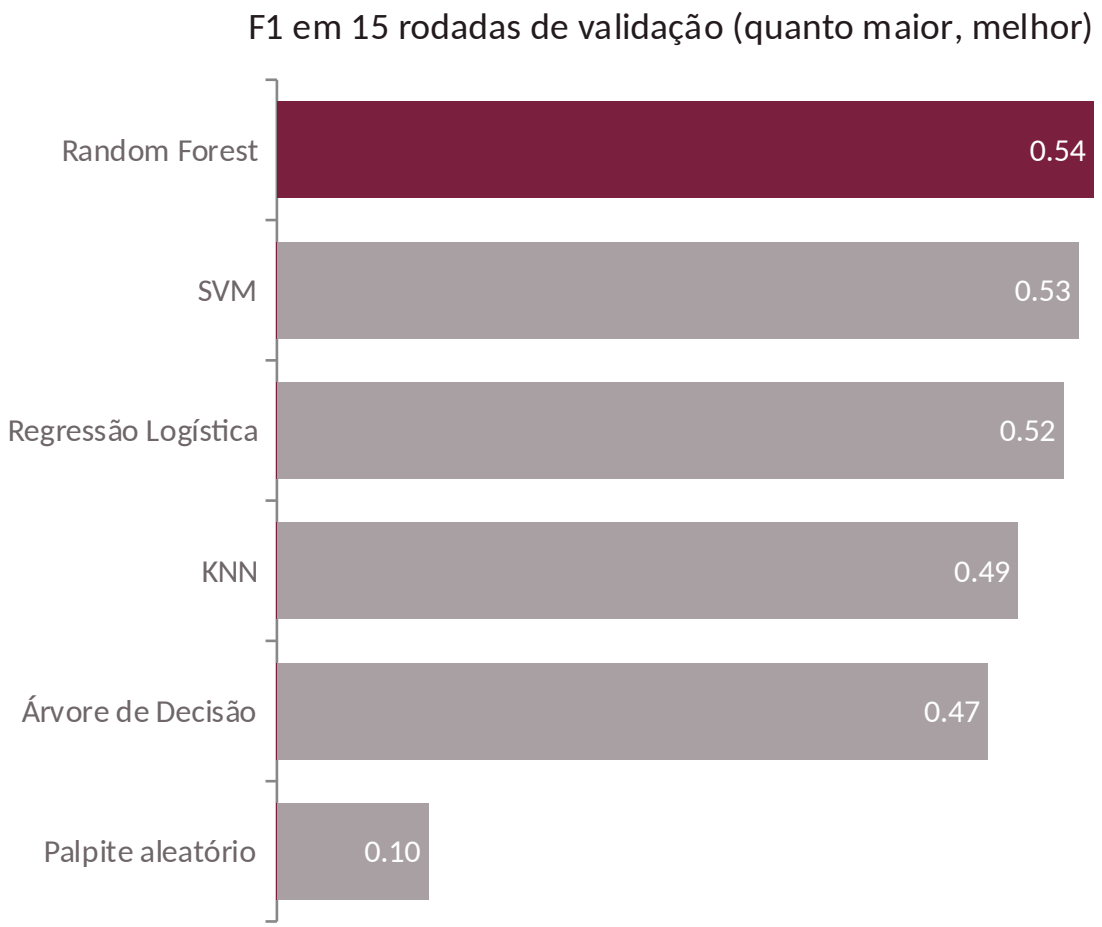
Grupos equilibrados no treino

Como os excelentes são minoria, o modelo recebeu peso maior para eles durante o aprendizado.

Medidas na mesma régua

As escalas variam de 0,99 (densidade) a 289 (SO_2). Padronizamos para nenhuma dominar só pelo tamanho.

Cinco modelos testados: a Random Forest foi a mais consistente



Por que a Random Forest

- Melhor resultado médio na validação cruzada e no teste
- Ordena melhor os vinhos: em 9 de 10 pares (um excelente e um comum), dá nota maior ao excelente
- Lida bem com valores extremos e combinações de medidas
- SVM e Regressão Logística ficaram próximas; a Logística é usada para explicar o porquê

Na prática: 20% dos lotes concentram 70% dos vinhos excelentes

204

vinhos novos avaliados pelo modelo

27 eram excelentes (13%)

41

apontados como "excelentes"

20% dos vinhos

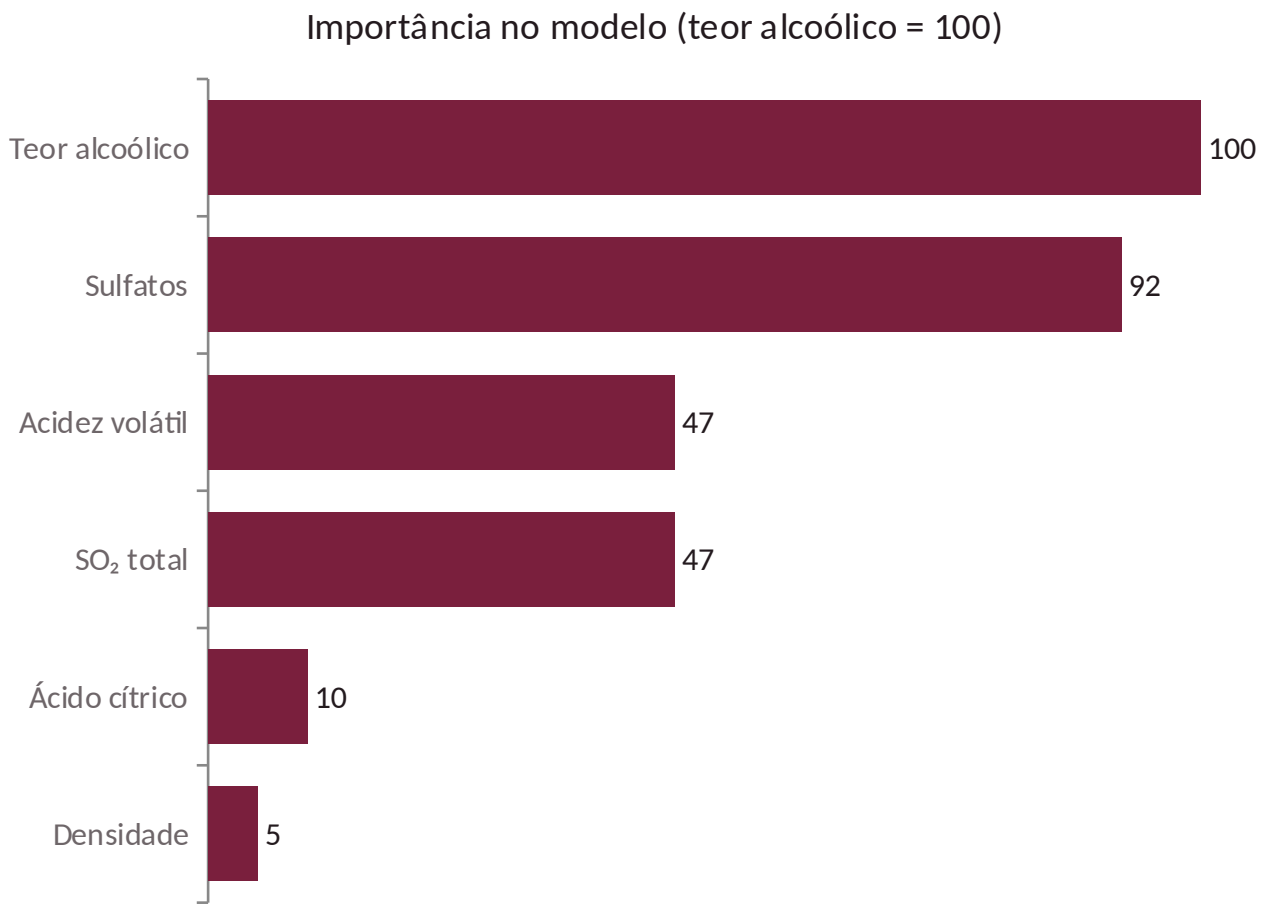
19

realmente eram excelentes

7 em cada 10 excelentes encontrados

46% de acerto ao apontar um vinho excelente — contra 13% ao acaso (≈ 3,5 vezes mais eficiente)
Uso sugerido: triagem de laboratório para priorizar a prova sensorial e sinalizar lotes de risco cedo. O modelo apoia o enólogo, não o substitui.

O que mais pesa na qualidade: álcool, sulfatos e acidez volátil



Teor alcoólico
mais álcool, mais chance de excelência

Sulfatos
conservação adequada favorece

Acidez volátil
o principal sinal de alerta

SO_2 total
conservante em excesso aparece nos comuns

Três métodos independentes (importância por permutação, coeficientes e árvore de regras) apontam os mesmos fatores.

Recomendações para o processo de produção



Controlar a acidez volátil

Higiene, temperatura e oxigênio na fermentação. Acompanhar o ácido acético e agir acima de ~0,4 g/dm³.



Colher no ponto certo de maturação

Álcool mais alto reflete uvas maduras e fermentação completa — não se trata de adicionar álcool.



Revisar o protocolo de conservação

Sulfatos perto de 0,7 g/dm³ nos melhores vinhos; evitar excesso de SO_2 total, que aparece nos comuns.



Usar o modelo como triagem

Priorizar lotes promissores para a prova sensorial e sinalizar lotes de risco ainda na produção.

Os dados mostram associação, não causa: validar cada recomendação com o enólogo e em lotes-piloto antes de mudar o processo.

Limites desta análise e próximos passos

Limites

- Base pequena: só 137 vinhos excelentes no total
- Apenas vinho tinto de uma região (Vinho Verde, Portugal)
- A nota vem de provadores: o modelo herda seus critérios
- Faltam dados como casta, safra e tempo de barrica

Próximos passos

- Validar as recomendações em lotes-piloto
- Ampliar a base, sobretudo com vinhos excelentes
- Testar o modelo com vinhos brancos
- Acompanhar o desempenho do modelo a cada safra

Os dados de laboratório já antecipam a qualidade

Mais álcool, sulfatos adequados e pouca acidez volátil marcam os vinhos excelentes — e um modelo simples de usar encontra 7 em cada 10 deles.



Código, análises e resultados: github.com/igorsycko/postech15dtat-tech-challenge-2-wine