RELATÓRIO TÉCNICO-EXECUTIVO • 01 DE NOVEMBRO DE 2026

O que faz um vinho ser excelente?

Como dados de laboratório podem antecipar a qualidade de vinhos tinto

Sumário

Síntese executiva 1
1. Compreensão do problema 3
2. Análise exploratória de Dados 3
Base, classes e distribuição das variáveis 3
Relações entre variáveis físico-químicas 4
Relação com a nota de qualidade 5
3. Pré-processamento de dados 6
Preparação sem vazamento entre treino e teste 6
4. Desenvolvimento de modelos 7
Cinco algoritmos comparados 7
5. Avaliação dos modelos 8
Resultado final no conjunto de teste 8
Matriz de confusão reconstruída 8
Erros e utilidade operacional 8
6. Interpretação e variações 9
Variáveis mais influentes no modelo 9
Hipóteses de produção a validar com o enólogo 9
Limitações que condicionam a conclusão 10
Referências do projeto 10

Síntese executiva

A análise transforma a nota sensorial em um alvo binário — alta qualidade quando a nota é ≥ 7 e baixa/média quando é < 7 — e testa se 11 medidas físico-químicas permitem priorizar vinhos tintos para avaliação sensorial. Após excluir 125 registros repetidos, restaram 1.018 amostras únicas, das quais 137 (13,5%) são positivas.

Entre cinco classificadores, a Random Forest foi selecionada com limiar 0,43 definido no treino. No teste, sinalizou 41 de 204 amostras e identificou 19 dos 27 vinhos de nota ≥ 7.

CONCLUSÃO DE USO

A evidência apoia um piloto de triagem para ordenar amostras e priorizar a prova sensorial. Não apoia, neste estágio, uma decisão automática de selo premium nem mudanças de produção sem validação com o enólogo

1. Compreensão do problema

A nota de qualidade é atribuída por especialistas em prova sensorial, processo subjetivo que depende da experiência de cada especialista. As medições químicas são coletadas durante a produção. A pergunta é com as medições de laboratório, conseguimos antecipar quais lotes serão de alta qualidade e saber o que ajustar no processo?

Definição e transformação da variável-alvo

Elemento	Definição adotada
Variável de origem	quality — nota sensorial observada na base, entre 3 e 8.
Transformação	alta_qualidade = 1 se quality ≥ 7; alta_qualidade = 0 se quality < 7.
Variáveis preditoras	11 medições físico-químicas; quality e Id não entram como preditoras.
Métrica de foco	F1 da classe positiva, complementado por precisão, recall, ROC-AUC e PR-AUC.

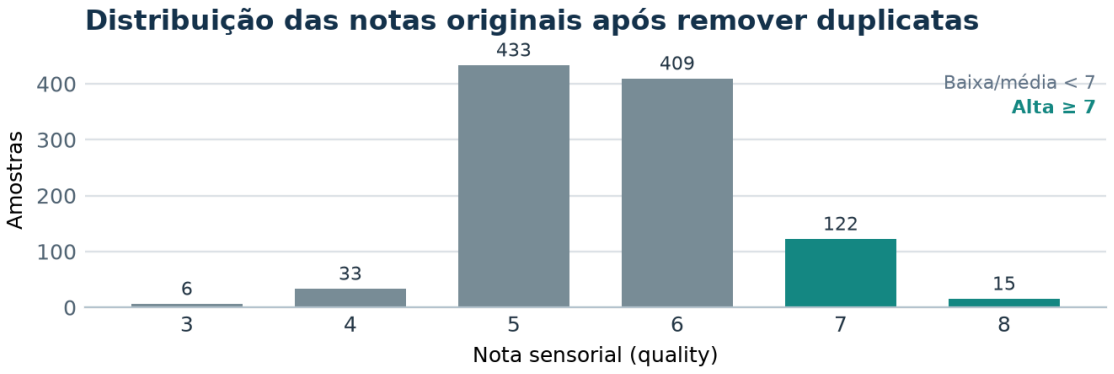
O corte separa o grupo de notas 7–8, aproximadamente o topo de 14% da amostra. Uma regra que previsse “baixa/média” para todos teria acurácia de 86,5% na base, mas recall zero para a classe de interesse; por isso, acurácia isolada não é critério de sucesso. [1] [2]

2. Análise exploratória de Dados

Base, classes e distribuição das variáveis

A base original contém 1.143 linhas. A EDA identificou 125 duplicatas exatas na combinação das 11 medidas químicas e da nota; removê-las deixa 1.018 registros únicos. O identificador Id foi excluído por não conter informação química. A EDA não reportou valores ausentes ou inconsistências.

Nota original	Amostras únicas	Classe binária
3	6	Baixa/média
4	33	Baixa/média
5	433	Baixa/média
6	409	Baixa/média
7	122	Alta
8	15	Alta
Total	1.018	137 alta (13,5%) / 881 baixa-média (86,5%)



Resumo descritivo:

Variável	Mediana	Mín.–máx.	Skew	Leitura da distribuição
Acidez fixa (g/dm³)	7,9	4,6–15,9	1,04	Cauda à direita
Acidez volátil (g/dm³)	0,52	0,12–1,58	0,72	Cauda à direita
Ácido cítrico (g/dm³)	0,25	0–1,00	0,37	Assimetria leve
Açúcar residual (g/dm³)	2,2	0,9–15,5	4,35	Cauda longa à direita
Cloretos (g/dm³)	0,079	0,012–0,611	5,93	Cauda longa à direita
SO_2 livre (mg/dm³)	13	1–68	1,17	Cauda à direita
SO_2 total (mg/dm³)	38	6–289	1,68	Cauda à direita
Densidade (g/cm³)	0,997	0,990–1,004	0,09	Próxima de simétrica
pH	3,31	2,74–4,01	0,26	Assimetria leve
Sulfatos (g/dm³)	0,62	0,33–2,00	2,42	Cauda longa à direita
Álcool (% vol.)	10,2	8,4–14,9	0,85	Cauda à direita

Outliers pelo critério exploratório não foram tratados como erro: valores extremos de cloretos, açúcar e sulfatos foram considerados reais/informativos e mantidos; a assimetria foi mitigada com log1p no pré-processamento. Não foram reportados valores inconsistentes.

Relações entre variáveis físico-químicas

A matriz de Pearson destacou os pares abaixo com $|r| \geq 0{,}4$. As explicações químicas são interpretações plausíveis descritas na EDA; correlação não prova mecanismo causal. A redundância indica multicolinearidade, relevante sobretudo para interpretar coeficientes lineares.

Par de variáveis	r	Justificativa reportada
Acidez fixa × pH	−0,69	Mais ácidos fixos elevam a concentração de H^+ e reduzem o pH; relação química direta.
Acidez fixa × densidade	+0,68	Ácidos dissolvidos aumentam a massa de solutos por volume e podem elevar a densidade.
Acidez fixa × ácido cítrico	+0,67	O ácido cítrico integra a acidez fixa, portanto as medidas compartilham informação.
SO_2 livre × SO_2 total	+0,66	O SO_2 livre é parte do total, formado pela fração livre mais a combinada.
Ácido cítrico × pH	−0,55	Compatível com o mecanismo ácido–pH: maior acidez cítrica associa-se a pH menor.
Acidez volátil × ácido cítrico	−0,54	Padrão compatível com consumo de cítrico e produção de acético em atividade bacteriana; hipótese, não causalidade demonstrada.
Densidade × álcool	−0,50	O etanol é menos denso que a água; fermentação também converte açúcar, mais denso, em álcool.

Relação com a nota de qualidade

Nenhuma variável isolada apresenta correlação forte com a nota (máximo $|r| \approx 0{,}5$), o que favorece modelos multivariados. Os sinais mais claros são álcool (+0,49), acidez volátil (−0,41), sulfatos (+0,26 em Pearson; +0,39 em Spearman) e ácido cítrico (+0,24). Densidade (−0,19) é um sinal indireto associado ao álcool; SO_2 total (−0,18), cloretos (−0,12 em Pearson; −0,21 em Spearman) e acidez fixa (+0,12) têm associações menores. pH, SO_2 livre e açúcar residual ficaram próximos de zero no conjunto.

3. Pré-processamento de dados

Preparação sem vazamento entre treino e teste

A preparação foi desenhada para preservar o teste até a avaliação final. Transformações que aprendem parâmetros — como o StandardScaler — são ajustadas apenas dentro do Pipeline e com dados de treino, incluindo os folds de validação cruzada.

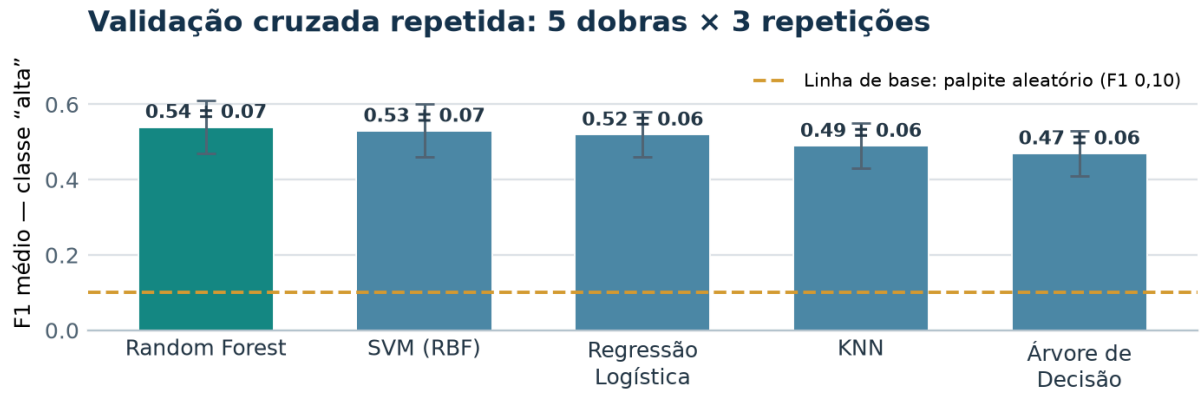
Decisão	Implementação no projeto	Motivo / controle
Identificador e alvo	Remover Id; construir alta_qualidade a partir de quality ≥ 7; excluir quality das preditoras.	Id não mede composição; manter quality como entrada causaria vazamento do alvo.
Duplicatas	Remover 125 linhas repetidas pela combinação das 11 medidas + nota.	Evitar peso duplicado e amostras praticamente idênticas em treino e teste.
Dados faltantes	Nenhuma imputação: EDA não encontrou nulos.	Evitar transformação desnecessária.
Feature engineering	Acidez total; proporção SO_2 livre/total; SO_2 combinado; interação álcool × sulfatos.	Resumir relações químicas observadas e testar informação adicional.
Assimetria/outliers	Aplicar log1p às variáveis assimétricas; preservar extremos reais.	Reduzir caudas longas sem descartar observações informativas.
Escala	StandardScaler dentro do Pipeline, ajustado apenas no treino.	Necessário para KNN, SVM e Regressão Logística; reduz efeito de unidades diferentes.
Desbalanceamento	Pesos balanceados; para KNN, oversampling limitado ao treino.	Dar atenção à classe minoritária sem contaminar validação/teste.
Divisão	80% treino / 20% teste, estratificada; teste guardado até a etapa 5.	Preservar a proporção de classes e obter avaliação final separada.

4. Desenvolvimento de modelos

Cinco algoritmos comparados

Foram treinados modelos de famílias distintas: Regressão Logística, KNN, SVM com kernel RBF, Árvore de Decisão e Random Forest. Os hiperparâmetros foram ajustados por GridSearchCV com StratifiedKFold de cinco dobras, escolhendo F1 da classe alta. A robustez foi resumida por validação cruzada repetida de 5 dobras × 3 repetições.

Modelo	F1 CV (5×3)	ROC-AUC CV	PR-AUC CV	Leitura
Random Forest	0,54 ± 0,07	0,88	0,59	Maior F1 médio; selecionado
SVM (RBF)	0,53 ± 0,07	0,87	0,56	Próximo ao melhor
Regressão Logística	0,52 ± 0,06	0,89	0,58	Explicativa; ROC-AUC CV mais alto
KNN	0,49 ± 0,06	0,87	0,55	Desempenho intermediário
Árvore de Decisão	0,47 ± 0,06	0,79	0,41	Menores métricas entre os modelos
Palpite aleatório	0,10	—	—	Linha de base informada



Barras de erro = desvio-padrão reportado; não são intervalos de confiança.

5. Avaliação dos modelos

Resultado final no conjunto de teste

O teste corresponde a 20% da base duplicada e foi mantido separado durante o ajuste. O limiar 0,43 da Random Forest foi escolhido no treino usando probabilidades fora da dobra, não otimizado no teste. As métricas abaixo são da classe “alta qualidade”, exceto ROC-AUC, PR-AUC e especificidade, que resumem aspectos distintos da discriminação.

Métrica	Resultado	Interpretação
ROC-AUC	0,91	O escore ordena corretamente cerca de 9 em 10 pares alta–baixa.
PR-AUC	0,69	Desempenho de precisão/recall considerando a classe positiva rara.
Precisão	0,46	19 dos 41 casos sinalizados como alta eram realmente alta qualidade.
Recall	0,70	19 dos 27 vinhos bons do teste foram encontrados.
F1	0,56	Compromisso entre precisão e recall para a classe alta.
Especificidade	≈0,88	Reconheceu corretamente cerca de 88% dos vinhos baixa/média.

Matriz de confusão reconstruída

Contagens reproduzidas a partir dos números publicados no README e no notebook de modelagem: 204 amostras de teste, 41 previstas como alta, 19 verdadeiros positivos e 8 falsos negativos. Os totais são coerentes com as métricas arredondadas.

Previsão do modelo	Real: alta (≥ 7)	Real: baixa/média (< 7)	Total previsto
Alta	19 verdadeiros positivos	22 falsos positivos	41
Baixa/média	8 falsos negativos	155 verdadeiros negativos	163
Total real	27	177	204

Erros e utilidade operacional

Dos 22 falsos positivos, 19 tinham nota 6; dois tinham nota 5 e um tinha nota 4. Os oito falsos negativos eram nota 7. Apenas cerca de 3% dos vinhos nota 5 foram sinalizados como alta. O erro se concentra na fronteira sensorial do corte, e não em confundir sistematicamente notas muito baixas com altas. [3]

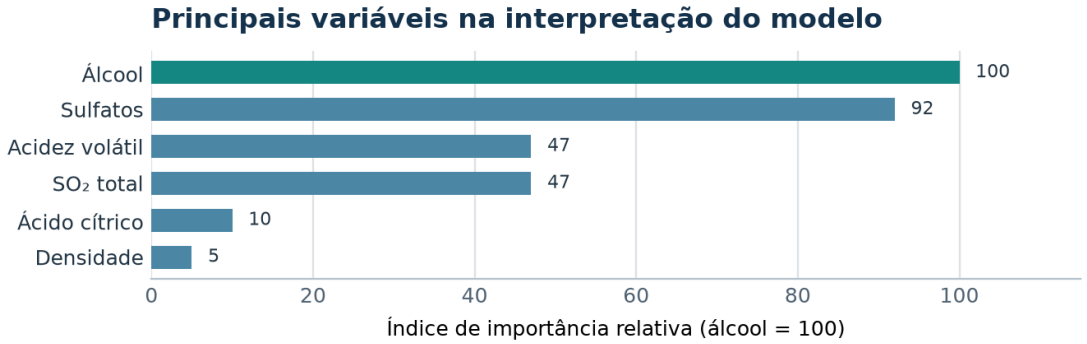
LEITURA PARA A OPERAÇÃO

O modelo sinaliza cerca de 20% das amostras e encontra 70% dos vinhos bons. A precisão de 46% supera a taxa-base de 13,5% em aproximadamente 3,4 vezes. Isso é útil para priorizar degustações; não equivale a uma taxa de aprovação premium.

6. Interpretação e variações

Variáveis mais influentes no modelo

A importância por permutação da Random Forest foi calculada no teste com average precision e 30 repetições: embaralha-se uma variável e mede-se a queda da PR-AUC. O índice abaixo normaliza a queda observada pela variável álcool para 100; a apresentação e a interpretação por coeficientes/árvore apontam a mesma ordem geral. Importância preditiva não mede efeito causal.



Hipóteses de produção a validar com o enólogo

Sinal do modelo / EDA	Hipótese operacional	Limite da interpretação
Mais álcool (+)	Acompanhar maturação da uva e completude da fermentação.	Não significa adicionar álcool; pode refletir outros fatores.
Acidez volátil (−)	Revisar higiene, temperatura, oxigênio e risco de contaminação; monitorar ácido acético.	~0,4 g/dm³ foi corte exploratório da árvore, não limite regulatório.
Sulfatos (+)	Revisar protocolo de conservação e a faixa em que o sinal satura.	Associação não prescreve dose; evitar extrapolar além da amostra.
SO_2 total (−)	Investigar excesso de conservante e avaliar impacto sensorial.	SO_2 total é variável distinta de sulfatos.
Ácido cítrico (+); cloretos (−)	Preservar frescor e investigar origem de sais quando elevados.	Sinais secundários, sujeitos a variação e interação com outras medidas.

LIMITAÇÕES, PRÓXIMOS PASSOS E FONTES

Limitações que condicionam a conclusão

- A base tem 1.018 amostras únicas e 137 vinhos de alta qualidade; no teste havia apenas 27 positivos. Uma observação altera o recall em cerca de 3,7 pontos percentuais, portanto as métricas têm incerteza relevante.
- O escopo é vinho tinto Vinho Verde, de uma fonte/região. O desempenho não deve ser presumido para vinhos brancos, outras castas, regiões ou safras.
- A nota é subjetiva e herdada dos provadores; o corte 6/7 separa casos quimicamente próximos. Faltam fatores como casta, safra, preço e tempo de barrica.
- A validação cruzada repetida reduz dependência de uma única divisão, mas não substitui validação externa com dados futuros de produção. Associação entre química e nota não demonstra causa.

Próximos passos recomendados

Passo	Ação
1. Piloto sombra	Aplicar o escore sem influenciar decisões e registrar notas de laboratório e painel sensorial.
2. Triagem assistida	Usar a ordenação para priorizar degustações; preservar o enólogo como responsável pela decisão.
3. Validar fora da amostra	Aumentar especialmente o número de vinhos bons; medir desempenho por safra e origem.
4. Definir limiar por custo	Escolher o ponto de corte com base no custo de falsos positivos e falsos negativos, sem reutilizar o teste.
5. Ampliar escopo com cautela	Avaliar outros estilos, incluindo brancos, em dados e modelos separados; não aplicar automaticamente este modelo.

Referências do projeto

[1]: https://github.com/igorsycko/postech15dtat-tech-challenge-2-wine/blob/main/README.md "README do projeto — objetivo, método e resultados"

[2]: https://raw.githubusercontent.com/igorsycko/postech15dtat-tech-challenge-2-wine/main/notebooks/01_eda.ipynb "Notebook 01 — compreensão do problema e análise exploratória"

[3]: https://raw.githubusercontent.com/igorsycko/postech15dtat-tech-challenge-2-wine/main/notebooks/02_modelagem.ipynb "Notebook 02 — pré-processamento, modelos, avaliação e interpretação"

[4]: https://github.com/igorsycko/postech15dtat-tech-challenge-2-wine/blob/main/presentation/apresentacao_executiva.pdf "Apresentação executiva do projeto"

[5]: https://github.com/igorsycko/postech15dtat-tech-challenge-2-wine/blob/main/data/WineQT.csv "Base WineQT.csv usada para estatísticas descritivas"

[6]: https://raw.githubusercontent.com/igorsycko/postech15dtat-tech-challenge-2-wine/main/src/config.py "Dicionário de variáveis e unidades do projeto"

Referência original da base: Cortez, P.; Cerdeira, A.; Almeida, F.; Matos, T.; Reis, J. “Modeling wine preferences by data mining from physicochemical properties”. Decision Support Systems, 47(4), 547–553, 2009. [1]